서술형 글쓰기 자동 채점: 표면 특징, 한국어 BERT, 그리고 채점자 간 한계

Term Project #1 · 김세훈 · 학번: 1102543003 · 코드: https://github.com/k01020989512-beep/aes-korean-essay

요약

AI Hub 서술형 글쓰기 평가 데이터(초5~중3, 36,006편, 종합점수 1~4)로 자동 채점(AES)을 수행했다. 1세대(표면 특징·문자 TF-IDF 릿지), 2세대(KLUE-RoBERTa 다중 과제 회귀)를 구현해 QWK로 비교했다. 2세대는 검증 세트 4,000편에서 QWK 0.538(채점자 평균)로 1세대(0.457)를 앞섰으나 사람 채점자 간 QWK 0.693에는 못 미쳤다. 분석 기준(8개)별로 보면 모델이 사람 수준에 근접한 항목(과제 수행, 글의 통일성)과 큰 격차가 남은 항목(어법, 문장 연결성)이 갈렸다. 글자 수는 점수와 거의 무관(r=0.09)해, 길이 편향이 아니라 내용·문체 신호를 학습했음을 확인했다. LLM-as-a-Judge(3세대)는 시간 제약으로 구현하지 못해 향후 과제로 남긴다.

1. 서론

자동 채점은 사람 채점자의 판단을 재현하는 기술로, 비용과 채점자 간 불일치를 줄이는 데 쓰인다. 본 연구는 한국어 서술형 글쓰기에서 (i) 표면 특징 기반 모델과 (ii) 사전학습 언어모델 회귀가 얼마나 사람 채점을 재현하는지, (iii) 사람 자체의 일치도가 상한으로 얼마나 높은지를 정량화한다.

2. 방법

데이터. 학습(Training) 32,006편, 평가(Validation) 4,000편. 학습 세트의 5%(1,600편)를 모델 선택용 dev로 분리했다. 학년은 초5~중3(5개 학년), 과목은 국어·사회·과학·수학, 지시문(주제)은 60개이며 평가 세트의 주제는 모두 학습 세트에도 있다. 채점자 2인이 종합 점수(1~4)와 분석 8개 항목(과제 수행, 설명 명료성·구체성·적절성, 문장 연결성, 글 통일성, 어휘, 어법)을 매겼다. 종합 점수 분포는 3점이 약 56%로 한쪽으로 쏠려 있다.

목표값·지표. 회귀 목표는 두 채점자 점수의 평균이다. 예측은 반올림 후 1~4로 잘라 QWK를 계산하고, 두 채점자 각각에 대한 QWK의 평균을 주지표로 쓴다. 사람-사람 QWK를 상한으로 둔다.

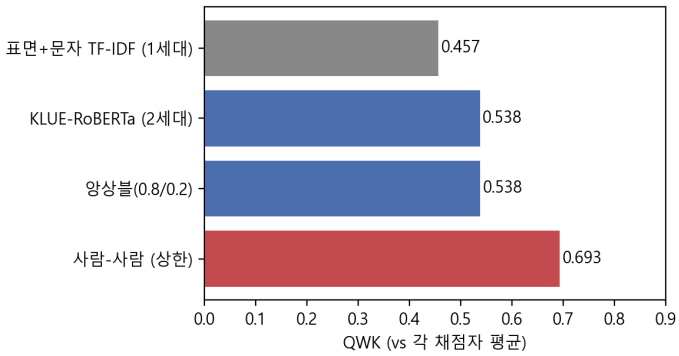
1세대. 길이·문장 수·TTR·핵심어 포함 수 등 10개 표면 특징, 여기에 문자 1~3-gram TF-IDF(20만 차원)를 더한 릿지 회귀.

2세대. klue/roberta-base에 [지시문, 글]을 쌍으로 입력(최대 320토큰), 평균 풀링 뒤 선형 헤드가 종합 점수와 분석 8개 점수를 동시에 회귀(종합 손실 가중 3배). AdamW 3e-5, 배치 16, 3에폭, fp16, RTX 3060 Ti. dev QWK가 가장 높은 에폭을 선택했다.

3. 결과

모델	QWK(채점자1)	QWK(채점자2)	QWK 평균	RMSE
길이만(릿지)	0.000	0.000	0.000	0.645
표면 특징(릿지)	0.140	0.139	0.139	0.579
표면+문자 TF-IDF(1세대)	0.458	0.456	0.457	0.498

KLUE-RoBERTa(2세대)	0.533	0.543	**0.538**	0.487
앙상블(0.8/0.2)	0.534	0.542	0.538	0.475
사람-사람(상한)	0.693		0.693	-

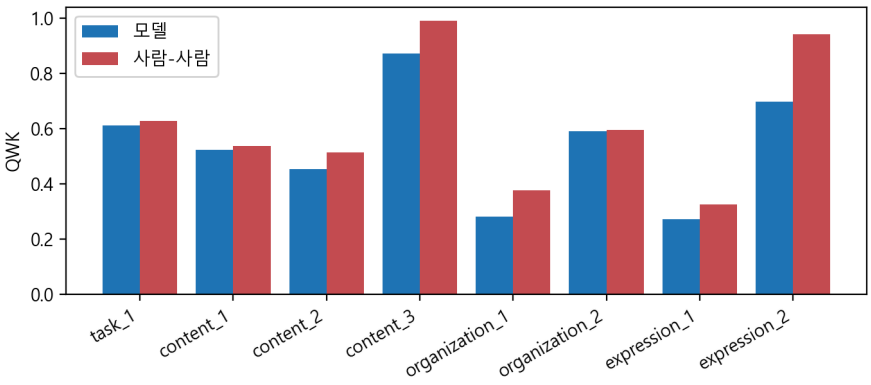


dev QWK는 에폭 1→3에서 0.397→0.474→0.526으로 계속 올랐다. 3에폭에서 멈췄으므로 학습이 덜 끝난 상태이고, 에폭을 늘리면 추가 향상 여지가 있다.

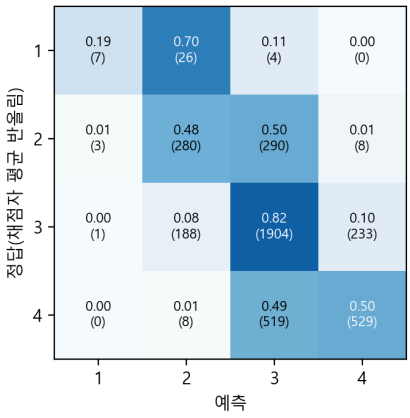
4. 분석

길이 편향 없음. 이 데이터는 최소 분량이 정해져 있어 글자 수와 점수의 상관이 낮다(라벨 r=0.087, 예측 r=0.093). 길이만 쓰면 QWK가 0이다. 영어 AES에서 흔한 "길면 고득점" 지름길이 여기서는 통하지 않는다.

항목별 격차. 분석 항목 QWK(모델 / 사람-사람): 과제 수행 0.61/0.63, 글 통일성 0.59/0.60, 설명 명료성 0.52/0.54, 설명 구체성 0.45/0.51, 문장 연결성 0.28/0.38, 어휘 0.27/0.33, 어법 0.70/0.94, 핵심어 적절성 0.87/0.99. 의미·구조 항목은 사람에 가깝지만, 맞춤법·띄어쓰기는 사람 일치도가 0.94로 거의 규칙적인데 모델은 0.70에 그친다. 서브워드 토큰화가 띄어쓰기 오류를 가려 버리는 점이 원인으로 보인다. 핵심어 항목은 지시문의 핵심어 포함 개수로 정해지는 규칙에 가까워, 명시적 핵심어 특징을 결합하면 개선될 여지가 있다.



중간 점수 쏠림. 정답 분포 대비 모델은 3점을 과다(2,717 대 2,326), 1·2·4점을 과소 예측한다. 특히 1점은 정답이 37편인데 1점으로 예측된 것은 11편뿐이다(혼동행렬). 회귀로 평균에 수렴하는 전형적 경향이다.



부분집단. 학년별 QWK는 0.505~0.560, 과목별 0.501~0.575로 고르다. 수학은 사람 일치도가 0.756으로 가장 높고 모델도 가장 높다(0.575). 모델-사람 격차는 모든 집단에서 약 0.14~0.19로 비슷했다.

5. 논의

사람 상한이 0.69인 점은 종합 점수 자체가 노이즈가 크다는 뜻이다. 채점자 1과 2는 약 30%에서 점수가 갈린다(교차표). 모델은 이 노이즈 위에서 학습·평가되므로 0.54는 상한 대비 약 78% 수준이다. 한편 항목별 결과는 종합 점수의 어려움이 의미 평가가 아니라 연결성·어휘 같은 주관적 항목에 몰려 있음을 시사한다. 한계: (1) 3에폭만 학습, 시드 1개라 신뢰구간이 없다. (2) 평가 세트의 60개 주제가 모두 학습 세트에도 있어 새 주제로의 일반화는 측정하지 못했다. (3) 3세대 LLM 채점을 하지 못했다.

6. 결론

한국어 서술형 AES에서 사전학습 모델은 표면 특징 기반보다 QWK를 0.457→0.538로 높였지만 사람 일치도 0.693에는 미치지 못했다. 향후: 더 긴 학습과 다중 시드, 철자·띄어쓰기 및 핵심어 규칙 특징 결합, 주제 단위 분할 평가, 루브릭 기반 LLM 채점과의 비교 및 앙상블.

참고문헌

Page (1966). The imminence of grading essays by computer. Phi Delta Kappan. · Attali & Burstein (2006). Automated essay scoring with e-rater V.2. JTLA. · Taghipour & Ng (2016). A neural approach to automated essay scoring. EMNLP. · Dong et al. (2017). Attention-based recurrent CNN for AES. CoNLL. · Park et al. (2021). KLUE: Korean Language Understanding Evaluation. · AI Hub 서술형 글쓰기 평가 데이터 (dataSetSn=71818).